

Desarrollo de un modelo de Machine Learning para la predicción de agresividad tumoral a partir de biomarcadores transcriptómicos

Introducción y contexto del proyecto

El análisis de datos transcriptómicos se ha convertido en una herramienta fundamental para comprender los mecanismos moleculares que subyacen al desarrollo y progresión del cáncer. En particular, la identificación de biomarcadores moleculares asociados a la agresividad tumoral permite mejorar la estratificación de pacientes y avanzar hacia enfoques de medicina personalizada.

El presente proyecto tiene como objetivo desarrollar un modelo de machine learning capaz de predecir el estadio patológico del tumor utilizando información derivada de la expresión génica y variables clínicas asociadas.

Este trabajo se divide en dos fases principales:

Project Break 1 — Exploratory Data Analysis (EDA)

En el EDA de diciembre ya se introdujo la enfermedad y se realizó un análisis exploratorio exhaustivo de los datos con el objetivo de:

- evaluar la calidad del dataset
- identificar valores faltantes y posibles outliers
- explorar la distribución de las variables clínicas
- analizar patrones de expresión génica
- identificar genes potencialmente asociados a la progresión tumoral

Durante esta fase también se aplicaron técnicas de reducción de dimensionalidad y análisis de redes de coexpresión, lo que permitió identificar un conjunto reducido de genes con relevancia biológica potencial.

Project Break 2 — Machine Learning


A partir de los resultados obtenidos en el EDA, se construyó un pipeline completo de modelado cuyo objetivo fue:

- entrenar modelos predictivos
- evaluar su rendimiento
- optimizar hiperparámetros
- analizar la interpretabilidad del modelo
- evaluar su potencial aplicación en contextos clínicos.

Selección de biomarcadores predictivos

Uno de los principales desafíos al trabajar con datos transcriptómicos es la alta dimensionalidad del dataset. Los perfiles de expresión génica pueden incluir decenas de miles de genes, lo que genera varios problemas en el contexto del aprendizaje automático: hay un aumento del riesgo de overfitting y se reduce la interpretabilidad del modelo, además de que haya una gran dificultad para identificar relaciones biológicas relevantes.

Para mitigar estos problemas, se realizó previamente un análisis de redes de coexpresión génica, técnica ampliamente utilizada en bioinformática para identificar módulos funcionales y genes reguladores clave. A partir de este análisis se seleccionaron los 10 genes más relevantes dentro de la red, definidos como aquellos que presentan alta conectividad (es decir, que “manda” sobre otros genes, los regula activándolos o desactivándolos, por lo que su actividad se encuentra interconectada con los mismos y los representa sin hacer uso de sus mismos datos de expresión), que tienen alta correlación con el fenotipo clínico y que podrían tener relación con la agresividad del tumor.



La selección de este conjunto reducido de biomarcadores permite construir modelos más parsimoniosos y clínicamente interpretables, manteniendo al mismo tiempo información biológica relevante.

Además de estos genes, se incluyó en el modelo la variable clínica **years_to_birth**, que representa la edad del paciente en el momento del diagnóstico. La edad es un factor clínico importante en oncología, ya que puede influir tanto en la progresión de la enfermedad como en la respuesta al tratamiento.

Construcción del dataset para modelado

Una vez definidos los biomarcadores, se construyó el dataset final utilizado para el entrenamiento de los modelos. Las variables features como ya hemos comentado serían la expresión de estos mismos 10 genes seleccionados junto con la edad del paciente (que ya vimos en el EDA que tenía gran importancia sobre la asignación de un estadio).

La variable objetivo corresponde a **pathologic_stage**, que representa el estadio patológico del tumor. En oncología, el estadio tumoral es uno de los indicadores más relevantes de la progresión de la enfermedad y suele clasificarse en diferentes categorías (Stage I, II, III y IV), reflejando el grado de invasión tumoral y posible diseminación metastásica.

Análisis del desbalanceo de clases

Uno de los aspectos más relevantes detectados durante la exploración del dataset fue la presencia de desbalanceo entre las clases de la variable target. Este fenómeno es común en datasets clínicos, donde determinadas condiciones o estadios de la enfermedad aparecen con menor frecuencia que otros (sobre todo porque la agresividad alta termina acabando con casos de decesos). El desbalanceo de clases puede afectar negativamente al rendimiento de los modelos de machine learning, ya que muchos algoritmos tienden a favorecer la clase mayoritaria durante el entrenamiento.

En este contexto, un modelo podría obtener una alta precisión global simplemente prediciendo siempre la clase más frecuente, sin aprender realmente a identificar los casos minoritarios. En aplicaciones médicas esto resulta especialmente problemático, ya que las clases minoritarias suelen corresponder precisamente a **los casos clínicamente más relevantes**, como tumores en estadios avanzados.

Separación de los datos en conjuntos de entrenamiento y test

Antes de aplicar cualquier técnica de preprocesamiento o balanceo se realizó una separación del dataset en training y test set. Esta división es un paso fundamental para evaluar correctamente la capacidad de generalización del modelo.

Además, este procedimiento evita el fenómeno conocido como **data leakage**, que ocurre cuando información del conjunto de test se filtra durante el proceso de entrenamiento, produciendo estimaciones de rendimiento artificialmente optimistas.

Para corregir el problema de desbalanceo detectado anteriormente se aplicó la técnica **SMOTE** (Synthetic Minority Oversampling Technique). Se trata de un método de sobremuestreo que genera ejemplos sintéticos de la clase minoritaria interpolando entre observaciones existentes en el espacio de características. A diferencia de técnicas simples de duplicación de muestras, SMOTE:

- aumenta la diversidad del dataset
- reduce el riesgo de overfitting

- mejora la capacidad del modelo para aprender patrones asociados a la clase minoritaria.

Es importante destacar que esta técnica se aplicó exclusivamente al conjunto de entrenamiento, manteniendo el conjunto de test sin modificaciones para preservar una evaluación realista del modelo.

Construcción del pipeline de modelado

Para estructurar el flujo de entrenamiento se utilizó un **Pipeline de Scikit-Learn**, que permite encadenar múltiples etapas de procesamiento en un único objeto reproducible.

El pipeline implementado incluye los siguientes pasos:

1. Estandarización de variables

Se aplicó un **StandardScaler** para normalizar las variables predictoras, transformándolas para que tengan media cero y desviación estándar uno. La estandarización es especialmente importante en modelos que dependen de distancias o que pueden verse afectados por diferencias de escala entre variables.

2. Modelo predictivo


El algoritmo seleccionado inicialmente fue **Random Forest**, un método de aprendizaje basado en ensembles de árboles de decisión.

Random Forest presenta varias ventajas en contextos biomédicos:

- capacidad para capturar relaciones no lineales
- robustez frente a ruido en los datos
- menor riesgo de overfitting en comparación con árboles individuales
- posibilidad de estimar la importancia relativa de las variables.

Evaluación inicial del modelo

Tras el entrenamiento inicial del modelo se evaluó su rendimiento utilizando métricas estándar de clasificación: precisión, recall y F1-score.



--- MÉTRICAS DETALLADAS ---

	precision	recall	f1-score	support
stagei	0.92	0.84	0.88	57
stageii	0.46	0.60	0.52	10
stageiii	0.48	0.50	0.49	22
stageiv	0.33	0.36	0.35	11
accuracy			0.69	100
macro avg	0.55	0.58	0.56	100
weighted avg	0.71	0.69	0.70	100

En el contexto de aplicaciones médicas, el **recall (sensibilidad)** es una métrica particularmente importante, ya que mide la capacidad del modelo para detectar correctamente los casos positivos. Un recall bajo implica que el modelo está dejando escapar casos que deberían ser identificados, lo que puede tener consecuencias clínicas relevantes.


Los resultados iniciales mostraron un rendimiento moderado, con dificultades para distinguir correctamente algunos estadios tumorales. Esto sugirió que el problema de clasificación multiclase podría ser demasiado complejo dado el tamaño limitado del dataset.

Reformulación del problema como clasificación binaria

Para mejorar el rendimiento del modelo se decidió reformular el problema de clasificación. En lugar de predecir múltiples estadios tumorales, se agruparon las categorías en estadio temprano y avanzado. Esta estrategia tiene varias ventajas desde el punto de vista estadístico y clínico:

- aumenta el número de muestras por clase
- simplifica el problema de clasificación
- refleja una distinción clínicamente relevante para la toma de decisiones terapéuticas.

Tras esta transformación se observó una distribución de clases más equilibrada. Con esto se reformuló el pipeline y se entrenaron los modelos en función del mismo.



Optimización de hiperparámetros

Una vez definido el modelo final se procedió a optimizar sus hiperparámetros utilizando **GridSearchCV**, técnica que permite evaluar sistemáticamente diferentes combinaciones de parámetros mediante validación cruzada. Entre los hiperparámetros explorados se incluyeron:


- número de árboles del bosque (n_estimators)
- profundidad máxima de los árboles (max_depth)
- pesos de clase para manejar posibles desbalances residuales.

La validación cruzada permite obtener una estimación más robusta del rendimiento del modelo al entrenarlo sobre múltiples particiones del dataset.

```
--- REPORTE DE CLASIFICACIÓN (BINARIO) ---
              precision    recall  f1-score   support

   tardio         0.70      0.79      0.74         33
   temprano         0.89      0.84      0.86         67

 accuracy              0.82         100
 macro avg              0.80      0.81      0.80         100
 weighted avg           0.83      0.82      0.82         100
```



Comparación

El pipeline se comparó con otros modelos, lo que permitió confirmar que los modelos basados en ensembles de árboles ofrecían un mejor equilibrio entre **recall y precisión** en este dataset.

```
--- Logistic Regression ---
      precision    recall  f1-score   support

   tardio         0.80      0.61      0.69         33
  temprano         0.83      0.93      0.87         67

 accuracy         0.82         100
macro avg         0.81      0.77      0.78         100
weighted avg      0.82      0.82      0.81         100

--- Random Forest ---
      precision    recall  f1-score   support

   tardio         0.76      0.67      0.71         33
  temprano         0.85      0.90      0.87         67

 accuracy         0.82         100
macro avg         0.80      0.78      0.79         100
weighted avg      0.82      0.82      0.82         100

--- SVM ---
      precision    recall  f1-score   support

   tardio         0.79      0.67      0.72         33
  temprano         0.85      0.91      0.88         67

 accuracy         0.83         100
macro avg         0.82      0.79      0.80         100
weighted avg      0.83      0.83      0.83         100
```

Estos además, también sufrieron la alteración de hiperparámetros para encontrar el mejor de todos, obteniendo que el ganador era random forest.

Logistic_Regression evaluado. Recall de Tardíos: 0.6970

Random_Forest evaluado. Recall de Tardíos: 0.8182


Gradient_Boosting evaluado. Recall de Tardíos: 0.7273

--- RANKING POR RECALL DE TARDÍOS (SIN SMOTE) ---

	Modelo	Recall_Tardio
1	Random_Forest	0.818182
2	Gradient_Boosting	0.727273
0	Logistic_Regression	0.696970


Random Forest Gradient Boosting

Comparativa de Modelos: Recall en Identificación de Tardíos



Ganador: Random_Forest

	precision	recall	f1-score	support
tardio	0.71	0.82	0.76	33
temprano	0.90	0.84	0.87	67
accuracy			0.83	100
macro avg	0.81	0.83	0.81	100
weighted avg	0.84	0.83	0.83	100



Resultados del ganador

Tras validar el modelo con un conjunto de datos "ciego" (Test Set), obtuvimos las siguientes métricas clave:

Sensibilidad (Recall) del 81.82%

Este es el éxito principal del proyecto. Significa que, de cada 100 pacientes que realmente están en una fase tardía de la enfermedad, el modelo es capaz de levantar la mano y avisar en 82 de ellos. Solo se nos escapan 18 casos, lo cual es una mejora drástica respecto a modelos no optimizados.

Precisión del 71.05%

Este valor indica la "limpieza" de nuestras alertas. Siete de cada diez alertas de "Estadio Tardío" son aciertos reales. Esto es vital para evitar el agotamiento del personal médico y la realización de biopsias o pruebas invasivas innecesarias en pacientes que realmente están en estadios tempranos.


El Equilibrio: F1-Score (0.76)

El F1-Score nos dice que el modelo es armónico. No hemos "comprado" el Recall a costa de destruir la precisión. El valor de 0.76 confirma que el modelo es estable y útil en un entorno de producción real.

Por otro lado, la gráfica de **Compromiso entre Captura de Casos y Falsas Alarmas** muestra una trayectoria ascendente muy particular.

Al analizar la curva, observamos que el modelo mantiene una precisión aceptable incluso cuando forzamos el Recall al máximo. En la presentación, esto justifica que el modelo es "elástico": si el hospital decide que puede permitirse más falsos positivos a cambio de no perder ni un solo paciente grave, el modelo permite ajustar el umbral de decisión para llegar a un Recall del 90% o más.


```
--- ANÁLISIS DE FIABILIDAD (Clase Tardío) ---  
Precisión (¿Cuánto acierto cuando digo 'Tardío?'): 0.7105  
Recall (¿Cuántos 'Tardíos' reales he capturado?): 0.8182  
F1-Score (Equilibrio entre ambas): 0.7606
```



Análisis de interpretabilidad del modelo

La interpretabilidad es un aspecto fundamental en aplicaciones de inteligencia artificial en medicina. Para analizar qué variables influyen más en las predicciones del modelo se

calculó la importancia de características (feature importance) proporcionada por Random Forest. Este análisis permite identificar qué biomarcadores contribuyen en mayor medida a la clasificación de los pacientes. La identificación de genes con alta importancia predictiva puede aportar información valiosa sobre los mecanismos moleculares asociados a la progresión tumoral.



Limitaciones del estudio

A pesar de los resultados obtenidos, el modelo presenta algunas limitaciones importantes:

1. Tamaño del dataset

El número de muestras disponibles es relativamente reducido, lo que puede limitar la capacidad de generalización del modelo.

2. Número limitado de biomarcadores

Aunque la selección de 10 genes mejora la interpretabilidad, es posible que otros biomarcadores relevantes no hayan sido incluidos. Además, y por supuesto, todas las afirmaciones que hemos tomado sobre los posibles biomarcadores deberían de contrastarse con la literatura que se tenga de la enfermedad y con análisis a nivel experimental antes de gastar un presupuesto en implementar un modelo así.

3. Falta de validación externa

El modelo ha sido evaluado únicamente en el dataset disponible. Para su aplicación clínica sería necesario validarlo en cohortes independientes.

Posibles mejoras futuras

Existen múltiples estrategias que podrían mejorar el rendimiento y la aplicabilidad clínica del modelo. Entre ellas destacan:

1. Integración multi-ómica

Combinar datos de diferentes capas biológicas, como mutaciones genómicas, metilación del ADN o proteómica, podría mejorar la capacidad predictiva del modelo.

2. Métodos avanzados de interpretabilidad

El uso de técnicas como SHAP values permitiría explicar las predicciones del modelo a nivel individual de paciente.

3. Validación multicéntrica

Evaluar el modelo en datasets procedentes de diferentes hospitales permitiría comprobar su robustez frente a variabilidad poblacional.

4. Integración en sistemas de apoyo a decisión clínica

El modelo podría incorporarse en plataformas de análisis molecular para ayudar a los clínicos en la estratificación de pacientes.

En general, los resultados obtenidos sugieren que los biomarcadores seleccionados contienen información relevante para la clasificación de pacientes según la agresividad tumoral, lo que abre la puerta a futuras aplicaciones en el ámbito de la **oncología computacional y la medicina personalizada**.